Q LEARNING

Ivan Androš Dejan Peretin Petra Podolski

Mentor: Dr. sc. Tomislav Šmuc

25. svibnja 2011.



Definicij*a*

Q LEARNING

- Tehnika učenja s podrškom.
- Agent uči evaluacijsku funkciju

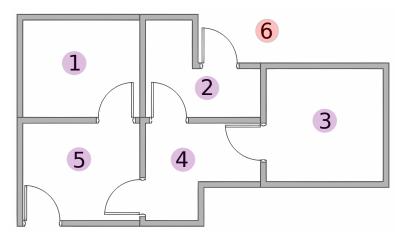
$$Q: S \times A \rightarrow \mathbb{R}$$

gdje je S skup stanja, a A skup akcija akcija.

Agentu ne mora biti poznat model okoliša.



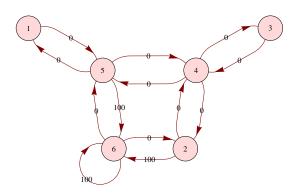
KRETANJE ROBOTA



SLIKA: Agent se nalazi u jednoj od soba, mora izaći van



Iotivacij.



SLIKA: Dijagram stanja prethodnog tlocrta



$$R = \begin{bmatrix} - & - & - & - & 0 & - \\ - & - & - & 0 & - & 100 \\ - & - & - & 0 & - & - \\ - & 0 & 0 & - & 0 & - \\ 0 & - & - & 0 & - & 100 \\ - & 0 & - & - & 0 & 100 \end{bmatrix}$$

$$R = \begin{bmatrix} - & - & - & - & 0 & - \\ - & - & - & 0 & - & 100 \\ - & - & - & 0 & - & - \\ - & 0 & 0 & - & 0 & - \\ 0 & - & - & 0 & - & 100 \\ - & 0 & - & - & 0 & 100 \end{bmatrix}$$

$$R = \begin{bmatrix} - & - & - & - & 0 & - & - \\ - & - & - & 0 & - & 100 \\ - & - & - & 0 & - & - & - \\ - & 0 & 0 & - & 0 & - & - \\ 0 & - & - & 0 & - & 100 \\ - & 0 & - & - & 0 & 100 \end{bmatrix}$$

$$R = \begin{bmatrix} - & - & - & - & 0 & - & 0 \\ - & - & - & 0 & - & 100 \\ - & - & - & 0 & - & - & - \\ - & 0 & 0 & - & 0 & - & 0 \\ 0 & - & - & 0 & - & 100 \\ - & 0 & - & - & 0 & 100 \end{bmatrix}$$

$$Q_{2,6} = R_{2,6} + 0.8 \cdot \max\{Q_{6,2}, Q_{6,5}, Q_{6,6}\} = 100 + 0.8 \cdot 0 = 100$$

$$Q_{2,6} = R_{2,6} + 0.8 \cdot \max\{Q_{6,2}, Q_{6,5}, Q_{6,6}\} = 100 + 0.8 \cdot 0 = 100$$



$$Q_{4,2} = R_{4,2} + 0.8 \cdot \max\{Q_{2,4}, Q_{2,6}\} = 0 + 0.8 \cdot 100 = 80$$



$$R = \begin{bmatrix} - & - & - & - & 0 & - \\ - & - & - & 0 & - & 100 \\ - & - & - & 0 & - & - \\ - & 0 & 0 & - & 0 & - \\ 0 & - & - & 0 & - & 100 \\ - & 0 & - & - & 0 & 100 \end{bmatrix}$$

$$R = \begin{bmatrix} - & - & - & - & 0 & - \\ - & - & - & 0 & - & 100 \\ - & - & - & 0 & - & - \\ - & 0 & 0 & - & 0 & - \\ 0 & - & - & 0 & - & 100 \\ - & 0 & - & - & 0 & 100 \end{bmatrix}$$

$$R = \begin{bmatrix} - & - & - & - & 0 & - \\ - & - & - & 0 & - & 100 \\ - & - & - & 0 & - & - \\ - & 0 & 0 & - & 0 & - \\ 0 & - & - & 0 & - & 100 \\ - & 0 & - & - & 0 & 100 \end{bmatrix}$$

$$Q_{2.6} = R_{2.6} + 0.8 \cdot \max\{Q_{6.2}, Q_{6.5}, Q_{6.6}\} = 100 + 0.8 \cdot 0 = 100$$



Nalaženje najkraćeg puta

$$Q = \begin{bmatrix} 0 & 0 & 0 & 0 & 400 & 0 \\ 0 & 0 & 0 & 320 & 0 & 500 \\ 0 & 0 & 0 & 320 & 0 & 0 \\ 0 & 400 & 256 & 0 & 400 & 0 \\ 320 & 0 & 0 & 320 & 0 & 500 \\ 0 & 400 & 0 & 0 & 400 & 500 \end{bmatrix}$$

Nalaženje najkraćeg puta

$$Q = \begin{bmatrix} 0 & 0 & 0 & 0 & 400 & 0 \\ 0 & 0 & 0 & 320 & 0 & 500 \\ 0 & 0 & 0 & 320 & 0 & 0 \\ 0 & 400 & 256 & 0 & 400 & 0 \\ 320 & 0 & 0 & 320 & 0 & 500 \\ 0 & 400 & 0 & 0 & 400 & 500 \end{bmatrix}$$

PUT: 3

Nalaženje najkraćeg puta

$$Q = \begin{bmatrix} 0 & 0 & 0 & 0 & 400 & 0 \\ 0 & 0 & 0 & 320 & 0 & 500 \\ 0 & 0 & 0 & 320 & 0 & 0 \\ 0 & 400 & 256 & 0 & 400 & 0 \\ 320 & 0 & 0 & 320 & 0 & 500 \\ 0 & 400 & 0 & 0 & 400 & 500 \end{bmatrix}$$

 $PUT: 3 \rightarrow 4$

Nalaženje najkraćeg puta

$$Q = \begin{bmatrix} 0 & 0 & 0 & 0 & 400 & 0 \\ 0 & 0 & 0 & 320 & 0 & 500 \\ 0 & 0 & 0 & 320 & 0 & 0 \\ 0 & 400 & 256 & 0 & 400 & 0 \\ 320 & 0 & 0 & 320 & 0 & 500 \\ 0 & 400 & 0 & 0 & 400 & 500 \end{bmatrix}$$

 $PUT: 3 \rightarrow 4$

Nalaženje najkraćeg puta

$$Q = \begin{bmatrix} 0 & 0 & 0 & 0 & 400 & 0 \\ 0 & 0 & 0 & 320 & 0 & 500 \\ 0 & 0 & 0 & 320 & 0 & 0 \\ 0 & 400 & 256 & 0 & 400 & 0 \\ 320 & 0 & 0 & 320 & 0 & 500 \\ 0 & 400 & 0 & 0 & 400 & 500 \end{bmatrix}$$

 $\mathrm{PUT}: \ 3 \ \rightarrow \ 4 \ \rightarrow \ 2$

Nalaženje najkraćeg puta

$$Q = \begin{bmatrix} 0 & 0 & 0 & 0 & 400 & 0 \\ 0 & 0 & 0 & 320 & 0 & 500 \\ 0 & 0 & 0 & 320 & 0 & 0 \\ 0 & 400 & 256 & 0 & 400 & 0 \\ 320 & 0 & 0 & 320 & 0 & 500 \\ 0 & 400 & 0 & 0 & 400 & 500 \end{bmatrix}$$

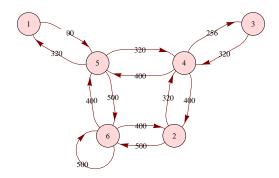
 $PUT: 3 \rightarrow 4 \rightarrow 2$

Nalaženje najkraćeg puta

$$Q = \begin{bmatrix} 0 & 0 & 0 & 0 & 400 & 0 \\ 0 & 0 & 0 & 320 & 0 & 500 \\ 0 & 0 & 0 & 320 & 0 & 0 \\ 0 & 400 & 256 & 0 & 400 & 0 \\ 320 & 0 & 0 & 320 & 0 & 500 \\ 0 & 400 & 0 & 0 & 400 & 500 \end{bmatrix}$$

 $\mathrm{PUT}: \ 3 \ \rightarrow \ 4 \ \rightarrow \ 2 \ \rightarrow \ 6$

Nalaženje najkraćeg puta



SLIKA: Dijagram stanja iz perspektive funkcije Q



PSEUDOKOD UČENJA FUNKCIJE Q

```
učitaj parametar \gamma i matricu R inicijaliziraj vrijednosti matrice Q na 0 while nema konvergencije do
na slučajan način izaberi inicijalno stanje while nismo u završnom stanju do
izaberi jedno od mogućih akcija za trenutno stanje Q_{s,a} = R_{s,a} + \gamma \cdot \max_i \{Q_{a,a_i}\} postavi sljedeće stanje za trenutno stanje end while
```

PSEUDOKOD NALAŽENJA NAJKRAĆEG PUTA

učitaj matricu Q i početno stanje **while** trenutno stanje != finalno stanje **do** za trenutno stanje nadi akciju koja ima najveću vrijednost u matrici Q za trenutno stanje odaberi ono stanje u koje vodi prethodno odabrana akcija
 end while

Generiranje problema

CILJ RADA

Generirati velike probleme i ispitati kako algoritam skalira sa brojem stanja.



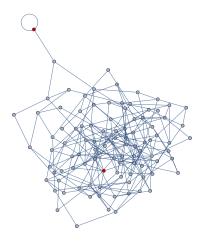
Generiranje problema

KAKO NA SLUČAJAN NAČIN GENERIRATI TLOCRT?

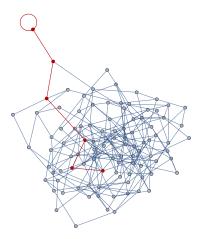
- graf mora biti povezan
- ne smije biti *pregust*
- na slučajan način generiramo nagrade



Generiranje problema

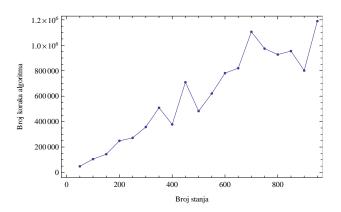


SLIKA: Dijagram sa 100 stanja



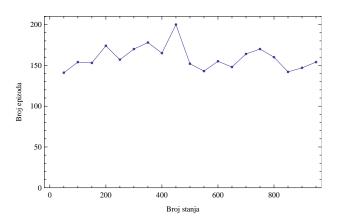
SLIKA: Dijagram sa 100 stanja





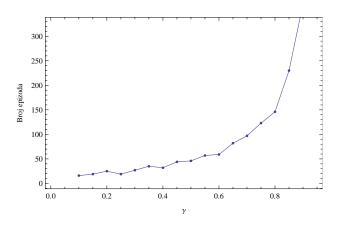
SLIKA: Broj koraka algoritma u odnosu na broj stanja





SLIKA: Broj epizoda u odnosu na broj stanja





 ${f SLIKA}$: Broj epizoda u odnosu na vrijednost γ

